

Análisis de datos

Carrera de Especialización en
Inteligencia Artificial
B5 2025



Programa de la materia

1 **Introducción al análisis de datos**
23/10 Flujo de trabajo típico. Aplicaciones. Configuración del entorno. Introducción a las principales bibliotecas. Introducción al EDA.

2 **Análisis exploratorio de datos (EDA)**
30/10 EDA. Estadística robusta. Visualización de variables numéricas y categóricas. Relación entre variables. Data cleaning y data wrangling. Identificación de valores faltantes y outliers.

3 **Taller práctico - parte 1**
6/11 Presentación de grupos de trabajo final. Práctica en salas virtuales: EDA y visualización inicial de un dataset. Puesta en común.

4 **Preprocesamiento y limpieza de datos**
13/11 Flujo de preparación de datos. Prevención de data leakage. Tratamiento de datos faltantes y outliers. Cardinalidad. Codificación. Discretización.

5 **Procesamiento (continuación)**
20/11 Normalización y estandarización. Técnicas avanzadas para el tratamiento de datos faltantes y outliers. Desbalance. Creación de nuevos features.

6 **Reducción de dimensionalidad**
27/11 Análisis estadístico inferencial. Técnicas para selección y extracción de features.
Bonus: EDA de datos no estructurados.

7 **Taller práctico - parte 2**
4/12 Práctica en salas virtuales: preprocesamiento y feature engineering de un dataset. Puesta en común.
Bonus: Herramientas para automatizar el EDA.



Martes 9/12 - límite para compartir el material para la exposición final.

8 **Exposición final**
11/12 (desdoblada en 2 sesiones, 11/12 y 15/12).
Exposición de trabajos finales

Dimensionalidad



Se llama **dimensionalidad** al número de variables (features) en un dataset.

a	b	c	d	e	f	g

Problemas con la alta dimensionalidad

Los datos con alta dimensionalidad son difíciles de analizar y visualizar. Además, pueden llegar a ocupar mucho espacio.

La maldición de la dimensionalidad

A medida que las dimensiones aumentan:

- los puntos de datos se vuelven escasos.
- las distancias entre puntos pierden significado.
- el costo computacional aumenta exponencialmente.
- se corre el riesgo de tener *overfitting*.


Solución

Crear un espacio de features de menor dimensión al original.



Técnicas de reducción de dimensionalidad

Selección de features




Elegir un subconjunto de features.

Ejemplo de aplicación:

- Existencia de features altamente correlacionadas.

Extracción de features



Transformar los datos en un espacio de menos dimensiones.

Ejemplo de aplicación:

- Análisis de datos genómicos.

Técnicas de selección de features

MÉTODOS DE FILTRADO

Evalúan las propiedades intrínsecas de las variables:

- Correlación (Pearson, Spearman, Kendall)
- Pruebas estadísticas (ANOVA, Chi-cuadrado, Información mutua)

MÉTODOS INTRÍNSECOS

Embebidos en el entrenamiento:

- Basados en árboles
- Basados en regularización (Regresión Lasso, SVM + L1)

MÉTODOS WRAPPER


Optimizan la performance predictiva:

- RFE (*Recursive Feature Elimination*)
- SFS (*Sequential Feature Selection*)
- *Permutation importance*



Nuestro foco

Análisis estadístico inferencial



Lo que hay que saber antes de continuar:

Test de hipótesis, ANOVA, chi-cuadrado,
correlación (Pearson, Kendall, Spearman).


Correlación con la variable target: Pearson

En qué consiste

- Mide la fuerza y la dirección de la asociación **lineal** entre dos variables. (No distingue cuál es la variable dependiente y cuál la independiente).

Cómo se usa para seleccionar features

- Calcular coeficientes de correlación. Armar matriz de correlación.
- Seleccionar las *features* en base a los resultados.




Correlación con la variable target: Spearman y Kendall

En qué consiste

- Miden la fuerza y la dirección de la relación **monótona** entre las *features* y la variable target.

Cómo se usa para seleccionar features

- Calcular coeficientes de correlación. Armar matriz de correlación.
- Seleccionar las *features* en base a los resultados.




Pruebas estadísticas: ANOVA

En qué consiste

- Mide si las medias de una *feature* son significativamente diferentes entre las clases (relación lineal *feature-target*).

Cómo se usa para seleccionar features

- Calcular el F-score para cada feature numérica.
- Seleccionar las *features* que tengan mayor F-score.



Pruebas estadísticas: chi-cuadrado

En qué consiste

- Mide el grado de dependencia entre dos variables categóricas.

Cómo se usa para seleccionar features

- Para cada *feature* categórica, calcular el valor χ^2 respecto al target.
- Seleccionar las *features* con mayor estadístico χ^2 .



Pruebas estadísticas: información mutua

En qué consiste

- Se calcula en base a la entropía: $I(X, Y) = H(Y) - H(Y|X)$
- Mide cuánto se reduce la incertidumbre sobre la variable target al conocer una *feature*. Mide el poder predictivo que tiene la *feature* sobre el target.

Cómo se usa para seleccionar features

- Calcular la información mutua entre cada *feature* y el target.
- Seleccionar las *features* que tengan mayor puntaje de información mutua.



Pruebas estadísticas - resumen

En general, los métodos de filtrado basados en pruebas estadísticas consisten en:

- Evaluar cada feature de manera individual, midiendo su relación estadística con la variable target.
- Seleccionar un método estadístico (ANOVA, χ^2 , información mutua, etc.) y calcularlo para cada *feature*.
- Ordenar las características según el puntaje obtenido, y
- Seleccionar las K mejores features según el criterio elegido.

Se pueden aplicar:

- Manualmente.
- con scikit-learn: usamos SelectKBest, SelectkFpr, etc.
- con otras herramientas: R, MATLAB, etc.

¿Cuándo usar cada método de filtrado?

TARGET		
feature	Numérica	Categórica
	• Pearson • Spearman • Kendall • Información mutua	• ANOVA • Kendall (categórica ordinal) • Información mutua
	Numérica	Categórica
	• ANOVA • Kendall (categórica ordinal) • Información mutua	• Chi-cuadrado (valores positivos y discretos) • Información mutua

Supuestos y consideraciones

Filtro	Supuestos
Pearson	Captura relaciones lineales. Asume distribución Normal de los datos. Sensible a outliers.
Spearman	Asume relación monótona entre variables. Robusto ante outliers.
Kendall	Asume relación monótona entre variables. Robusto ante outliers. Mejor que Spearman si hay valores repetidos en cualquiera de las variables a comparar.
ANOVA	Supone normalidad de los datos en cada grupo y varianzas homogéneas (homocedasticidad). Alternativas: Kruskal-Wallis (no paramétrico) y Welch-ANOVA.
Información mutua	No asume ninguna distribución en particular. Puede capturar relaciones no lineales.

Ejemplo práctico



Extracción de features

Objetivo

Reducir la dimensionalidad conservando la mayor cantidad de información posible.

Algunas técnicas

- PCA (*Principal Component Analysis*)
- LDA (*Linear Discriminant Analysis*)
- t-SNE (*t-distributed Stochastic Neighbor Embedding*)
- UMAP (*Uniform Manifold Association and Projection*)

Análisis de los componentes principales (PCA)

PCA transforma un conjunto de variables en un nuevo conjunto de variables llamadas **componentes principales**.



Los componentes principales:

- son combinaciones lineales de las variables originales,
- son ortogonales (no correlacionados) entre sí, y
- están ordenados de modo que cada uno captura la mayor varianza posible.



Análisis de los componentes principales (PCA)

¿Por qué es importante la varianza?



- Recordemos: la varianza mide la dispersión de los datos alrededor de la media.
- En un dataset con muchos *features*, cada *feature* contribuye a la variación de los datos en mayor o menor medida.
- Retener la máxima varianza implica mantener las componentes que explican la porción más grande de esa variación.

Análisis de los componentes principales (PCA). Ejemplo.

DATOS

2	0	0
0	1	0
0	0	1
3	2	1

$X (4 \times 3)$

DATOS
estandarizados

0,75	-0,75	-0,50
-1,25	0,25	-0,50
-1,25	-0,75	0,50
1,75	1,25	0,50

$X' (4 \times 3)$

Matriz de
covarianza

2,25	0,75	0,1667
0,75	0,9167	0,1667
0,1667	0,1667	0,3333

$Cov (3 \times 3)$

Autovalores

λ_1	λ_2	λ_3
2,6082	0,6037	0,2882

PC1

PC2


PC3

Autovectores

-0,9063	-0,4216	0,0289
-0,4114	0,8647	-0,2883
-0,09654	0,27319	0,9571

$V (3 \times 3)$

Análisis de los componentes principales (PCA). Ejemplo.




Explicación de la varianza

PC1 74,52 %
PC2 17,25 %
PC3 8,23 %

$$\begin{matrix}
 \begin{matrix} 0,75 & -0,75 & -0,50 \\ -1,25 & 0,25 & -0,50 \\ -1,25 & -0,75 & 0,50 \\ 1,75 & 1,25 & 0,50 \end{matrix} & \times & \begin{matrix} \text{PC1} & \text{PC2} \\ -0,9063 & -0,4216 \\ -0,4114 & 0,8647 \\ -0,09654 & 0,27319 \end{matrix} & = & \begin{matrix} -0,323 & -1,101 \\ 1,078 & 0,607 \\ 1,393 & 0,015 \\ -2,149 & 0,480 \end{matrix} \\
 X' (4 \times 3) & & W (3 \times 2) & & Y (4 \times 2)
 \end{matrix}$$


Análisis de los componentes principales (PCA)

En general:



Análisis de los componentes principales (PCA)

En general:



Ejemplo práctico en Jupyter






Uniform Manifold Approximation and Projection

UMAP es una técnica de reducción de dimensionalidad que puede ser usada:

- para visualización (ej. para clustering)
- para reducción de dimensionalidad (no lineal).

[UMAP project](#)

[UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction](#)




UMAP paso a paso

Crea una proyección en un espacio de dimensiones reducidas que preserva clusters presentes en los datos originales y la relación entre ellos.

Funcionamiento (Ej: 2D a 1D)

- 1) Calcula distancias entre todos los puntos.
- 2) Arma un mapa de vecinos y similitudes.
- 3) Inicializa el espacio de dimensión reducida (1D).
- 4) Calcula similitudes en el espacio reducido.
- 5) Ajusta una función para minimizar la diferencia de similitudes entre los espacios 2D y 1D.



Ejemplo práctico






Siempre hay un “pero”...





- Al reducir dimensiones se pierde información.
- Técnicas como PCA transforman los features originales y después cuesta interpretarlos.
- La efectividad de la técnica depende del dataset y del problema en cuestión.

Técnicas de selección vs técnicas de reducción



Aspecto	Selección	Extracción
En qué consiste	Conservar un subconjunto de las variables originales (las más relevantes).	Crear nuevas variables (componentes) combinando las originales.
En qué tipo de datasets aplicarla	Dimensionalidad moderada	Dimensionalidad alta
Interpretabilidad	Alta	Baja
Técnicas	Correlación con la v. target - Correlación pairwise - ANOVA - Chi-cuadrado - Información mutua - otras	PCA - LDA - t-SNE - UMAP - otras.

Técnicas de selección vs técnicas de reducción




Ejemplo	Selección	Extracción
Predicción de riesgo de enfermedad con 100 indicadores medidos en sangre.	Usando ANOVA seleccionar solo los indicadores que muestran diferencias significativas entre enfermos y sanos, para preservar la interpretabilidad.	Si el objetivo es predecir rápidamente sin importar los indicadores, usar PCA para obtener factores latentes.
Predicción de abandono a partir de datos de 500 atributos de clientes (edad, ingresos, compras, etc.).	Filtrar con información mutua para conservar las 50 variables con más poder predictivo. Luego entrenar un modelo interpretable (ej. árboles).	Usar PCA para comprimir los 500 atributos en 10 componentes principales. Luego segmentar clientes con K-means.
Análisis de una red de sensores de una planta industrial (2000 lecturas de temperatura, humedad, etc.).	Calcular la matriz de correlación para identificar pares o grupos de sensores muy correlacionados y conservar solo uno.	Usar PCA para fusionar sensores correlacionados. Ej.: PCA puede obtener componentes latentes que mejor representen el calor o la humedad.

Flujo de preparación de datos

Split del dataset

Calcular y aplicar las transformaciones



BONUS!



EDA y preprocesamiento para diferentes tipos de datos

DATOS TABULARES

- variables numéricas y categóricas.
- medias, desvíos, histogramas, etc.

DATOS NO ESTRUCTURADOS

- palabras, píxeles, frecuencias.
- usa visualizaciones y métricas adaptadas a la naturaleza específicas de cada tipo de dato.

En todos los casos se buscan patrones, anomalías, tendencias, desbalanceos, problemas de calidad.




EDA y preprocesamiento para Texto

Qué analizamos en un texto

- Corpus: cantidad de documentos y de palabras.
- Longitud de textos (documentos, oraciones).
- Frecuencia de palabras / tokens.
- Distribución de clases (si es clasificación).
- N-gramas frecuentes.
- TF, DF, TF-IDF (términos relevantes)

Limpieza y preparación de texto

- Eliminar stopwords, signos de puntuación, errores ortográficos.
- Normalizar abreviaturas o expresiones.
- Embeddings + PCA / t-SNE



ne end of the
h how you're livin
ether you're com
nd your free time
ers. It's how you
nd you. It's wh


EDA y preprocesamiento para Audio (o Señales)

Qué analizamos en un audio

- Duración, amplitud, volumen, formas de onda.
- Espectrogramas
- Análisis de pitch (para analizar entonación, melodía, etc., para distinguir voces, instrumentos, emociones).
- Distribución de clases (si es clasificación)

Limpieza y preparación de audio

- Eliminar archivos corruptos.
- Identificar y remover ruidos, silencios, interferencias.
- Recortar fragmentos irrelevantes.
- Normalizar el volumen.



EDA y preprocesamiento para Imágenes

Limpieza de imágenes

- Eliminar imágenes corruptas.
- Normalizar tamaños o resoluciones.
- Reducir ruido (filtros de mediana, gaussiano).



Análisis y visualización

- Visualizamos imágenes aleatorias.
- Distribución de los valores de los píxeles (histogramas)
- Colores, texturas, formas, iluminación, enfoque, orientación, ruido etc.
- Evaluación de la distribución de clases (desbalance?)



EDA y preprocesamiento para Imágenes

Preparación de imágenes para entrenamiento

- Etiquetado.
- Balancear clases (oversampling / undersampling).
- Data augmentation (rotar, voltear, recortar).
- Selección / extracción de features.



Ejemplo

Imágenes de radiografías con intensidades, texturas, bordes, medidas, etc.

- Selección: quedarse solo con los píxeles con intensidades superiores a un umbral.
- Extracción: transformar las *features* en nuevas representaciones que resuman las texturas y bordes en factores latentes.



Ejemplos prácticos



¿Te quedaron dudas?



- Recordá que podés consultarnos durante la clase preniendo la cámara y hablando, o simplemente escribiendo en el chat.
- También podés escribirnos por correo las veces que sea necesario (por favor incluir a ambas docentes).



Esp. Lic. María Carina Roldán
macroldan@fi.uba.ar



Esp. Ing. Ariadna Garmendia
arigarmendia@gmail.com

Y si tenés un feedback, un pedido, una sugerencia, etc. y no te animás a decirlo, podés dejarlo por escrito en la encuesta voluntaria y anónima (disponible durante todo el bimestre).