

Análisis de datos

Análisis estadístico

inferencial para

selección de features

Carrera de Especialización en
Inteligencia Artificial
B5 2025



Análisis estadístico inferencial para selección de features

- 1 CORRELACIÓN DE PEARSON**
- 2 CORRELACIÓN DE SPEARMAN Y KENDALL**
- 3 TEST DE HIPÓTESIS**
- 4 ANOVA**
- 5 TEST DE CHI-CUADRADO**

Correlación de Pearson

Coeficiente de correlación de Pearson para n muestras:

$$r_{XY} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

- Mide la **fuerza** y la **dirección** de la **asociación lineal** entre dos variables.
- Asume que la distribución de los datos es Normal.
- No distingue cuál es la variable dependiente y cuál la independiente. ($r_{XY} = r_{YX}$)
- **Muy importante!** la correlación no indica ninguna medida de la importancia significativa de la relación (es decir, si esto vale también para la población de los datos y no solo en la muestra).

Resultado:

- $r=1$ ó $r=-1$: indica que x e y están perfectamente relacionadas (-1 indica que cuando una crece, la otra decrece).
- $0 < r < 1$: hay una relación lineal, pero no perfecta

Correlaciones por rankings de Spearman y Kendall

Coeficiente de correlación de Spearman para n muestras:

$$r_s = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$$

- d_i son las diferencias entre rankings

Coeficiente de correlación de Kendall para n muestras:

$$\tau = \frac{C - D}{\frac{n(n-1)}{2}} = \frac{C - D}{C + D}$$

- C = número de pares concordantes
- D = número de pares discordantes

- Miden la fuerza y la dirección de una relación monótona entre dos variables.
- No asumen distribución Normal de los datos.
- Son robustos a outliers.
- Ambos utilizan rankings para hacer los cálculos.
- Los resultados están en $[-1, 1]$ al igual que con Pearson.
- Usar Kendall cuando hay empates (cuando las variables tienen valores repetidos). porque Spearman pierde.

Ejemplo

Tests de hipótesis

Un test de hipótesis es una manera formal de elegir entre dos opciones o hipótesis.


Ejemplo cotidiano: un juicio

En un juicio se cuenta con dos hipótesis:

- La persona es inocente.
- La persona es culpable.

Se parte de la **presunción de inocencia** (inocente hasta que se demuestre lo contrario).

El objetivo del juicio es recolectar **evidencias** para rechazar la inocencia.



Si $P(\text{evidencias} \mid \text{el acusado es inocente}) \leq \text{umbral}$
entonces se considera que se demostró culpabilidad.

Tests de hipótesis

Un test de hipótesis es una manera formal de elegir entre dos opciones o hipótesis.

Ejemplo cotidiano: un juicio

el test

En un juicio se cuenta con dos hipótesis:


- La persona es inocente.
- La persona es culpable.

hipótesis nula

H_0

hipótesis alternativa

H_1



Se parte de la **presunción de inocencia** (inocente hasta que se demuestre lo contrario).

El objetivo del juicio es recolectar **evidencias** para rechazar la inocencia.

estadísticos

p-valor

significancia

Si $P(\text{evidencias} \mid \text{el acusado es inocente}) \leq \text{umbral}$
entonces se considera que se demostró culpabilidad.

Tests de hipótesis

Un test de hipótesis es una manera formal de elegir entre dos opciones o hipótesis.

Ejemplo cotidiano: un juicio

el test

En un juicio se cuenta con dos hipótesis:


- La persona es inocente.
- La persona es culpable.

hipótesis nula

H_0

hipótesis alternativa

H_1



Se parte de la **presunción de inocencia** (inocente hasta que se demuestre lo contrario).

El objetivo del juicio es recolectar **evidencias** para rechazar la inocencia.

estadísticos

p-valor

significancia

Si $P(\text{estadísticos} \mid \text{hipótesis nula } H_0 \text{ es V}) \leq \text{umbral}$
entonces se acepta la hipótesis alternativa H_1 como V.

Tests de hipótesis

Se quiere determinar si los pingüinos de las especies Adelie y Chinstrap tienen o no el mismo largo promedio de aleta.

Test

- Defino las hipótesis.


$$H_0 : \theta_1 = \theta_2$$

$$H_1 : \theta_1 \neq \theta_2$$

- Elijo el nivel de significancia.

$$\alpha = 0,05$$

- Selecciono el estadístico de prueba.
- Calculo el estadístico con los datos muestrales.
- Calculo el *p*-valor.
- Tomo la decisión.



Decisión

- Si $p \leq 0,05$, rechazamos H_0 . Hay evidencia suficiente para concluir que el largo promedio de la aleta es diferente entre los pingüinos de las especies Adelie y Chinstrap.
- Si $p > 0,05$, no rechazamos H_0 . No hay evidencia suficiente para afirmar que el largo promedio de la aleta es diferente entre los pingüinos de las especies Adelie y Chinstrap.

Atención! **No rechazar H_0 no es lo mismo que aceptar H_0 .**
La falta de evidencia puede deberse a una muestra insuficiente.

Tests de hipótesis

Funcionamiento general de una prueba de hipótesis

Prueba bilateral o de dos colas

$$H_0 : \theta = \theta_0$$

$$H_1 : \theta \neq \theta_0$$

Pruebas unilaterales o de una cola

$$H_0 : \theta = \theta_0$$

$$H_1 : \theta > \theta_0$$


$$H_0 : \theta = \theta_0$$

$$H_1 : \theta < \theta_0$$

En cualquiera de los casos se calcula un estadístico de prueba T_0 con base en los datos, a partir del cual se calcula $p = P(T > T_0 | H_0)$. Si $p < \alpha$, se rechaza H_0 .

ANOVA

Análisis de la varianza




ANOVA (Análisis de Varianza) es una técnica estadística que permite comparar las medias de tres o más grupos para determinar si existen diferencias significativas entre ellos.

Por ejemplo, si queremos ver si el peso corporal promedio difiere entre las tres especies, realizamos un ANOVA.

ANOVA

Análisis de la varianza




Hipótesis para llevar a cabo un ANOVA

- Independencia de los valores observados.
- Normalidad de los datos en cada una de las clases.
- Homogeneidad de varianzas.

ANOVA

Análisis de la varianza



Test

- Hipótesis nula (H_0): el peso corporal promedio de todas las especies es igual: $\mu_1 = \mu_2 = \dots = \mu_k$
- Hipótesis alternativa (H_1): al menos una especie tiene peso promedio diferente.
- Nivel de significancia: $\alpha = 0,05$ (95%)

Estadístico




Decisión

- Si $p \leq 0,05$, rechazamos H_0 . Las medias no son todas iguales.
- Si $p > 0,05$, no rechazamos H_0 . No hay evidencia de diferencias.

ANOVA

Análisis de la varianza




$$F =$$



ANOVA



Análisis de la varianza



variabilidad
entre grupos

ANOVA


Análisis de la varianza



variabilidad
intra grupos

ANOVA

Análisis de la varianza



$$F = \frac{\text{variabilidad entre grupos}}{\text{variabilidad intra grupos}}$$

Test de Chi-cuadrado

- Sirve para averiguar si hay una relación entre dos variables categóricas.
- Para el análisis compara las frecuencias observadas y las frecuencias esperadas (qué se esperaría ver si las variables fueran independientes)
- Un mayor valor del estadístico representa una relación más fuerte.

$$\chi^2 = \sum \frac{(O_i - E_i)^2}{E_i}$$

- O_i son las frecuencias observadas
- E_i son las frecuencias esperadas

Atención!

- Supuesto: las frecuencias esperadas son >5
- No está pensado para variables ordinales (en ese caso conviene usar análisis basado en rankings).

